

**UNIVERSIDAD MAYOR, REAL Y PONTIFICIA DE
SAN FRANCISCO XAVIER DE CHUQUISACA
FACULTAD DE TECNOLOGÍA**



Práctica Optimización de Procesos

Carrera : Ingeniería en Ciencias de la Computación

Universitario : Lujan Renteria David Fernando

Sucre – Bolivia

2025


1. Transfer Learning (Aprendizaje por Transferencia):

El transfer learning consiste en tomar un modelo preentrenado en una tarea grande (por ejemplo, clasificación de imágenes en ImageNet) y reutilizarlo para una tarea diferente pero relacionada. En lugar de entrenar un modelo desde cero, se aprovecha el conocimiento aprendido por el modelo en la tarea original.

Pasos comunes en transfer learning:

1. **Seleccionar un modelo preentrenado:** Es muy importante que escojamos un buen modelo debido a que actualmente existen un gran numero de modelos preentrenados para diferentes ámbitos, cada uno resalta por alguna característica o mayor desempeño en áreas, pero como estamos haciendo aprendizaje no usaremos el mas optimo si no uno bueno que nos ayude a que podamos entender estos conceptos.
2. **Congelar las capas iniciales:** Las primeras capas del modelo (que suelen aprender características generales, como bordes o texturas) se congelan para evitar que se modifiquen durante el entrenamiento ya que estas capas son por las que conviene usar un modelo ya preentrenado.
3. **Reemplazar las capas finales:** Las capas finales del modelo (que suelen ser específicas para la tarea original, como la clasificación en ImageNet) se reemplazan por nuevas capas adaptadas a la nueva tarea (por ejemplo, clasificación de un nuevo conjunto de clases).
4. **Entrenar el modelo:** Solo se entrenan las nuevas capas añadidas, utilizando el conjunto de datos de la nueva tarea.

Deep neural network




2. Fine-Tuning (Ajuste Fino):

El fine-tuning es una extensión del transfer learning. En lugar de congelar todas las capas del modelo preentrenado, se descongelan algunas capas adicionales y se ajustan sus pesos durante el entrenamiento. Esto permite adaptar el modelo aún más a la nueva tarea.

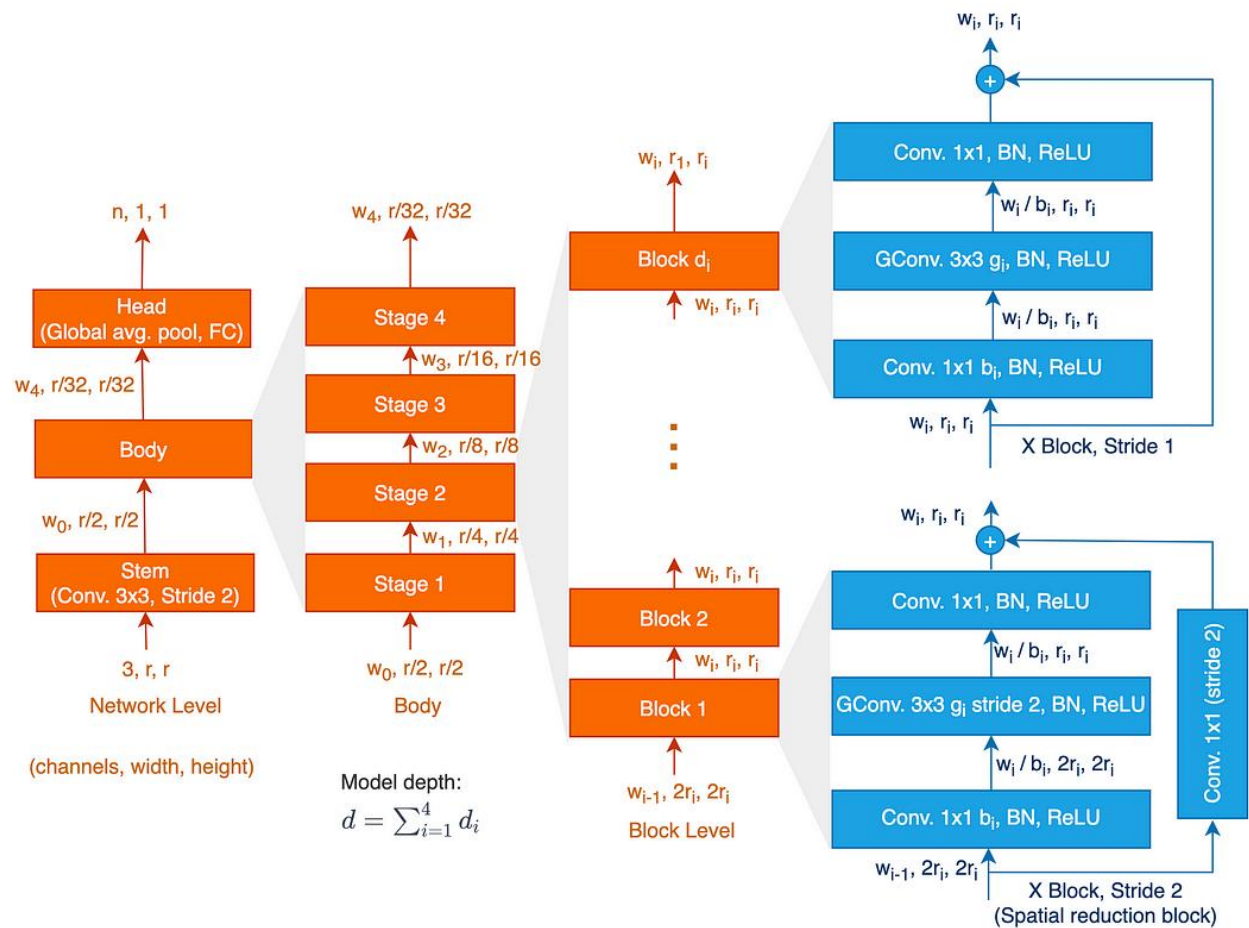
Pasos comunes en fine-tuning:

1. **Aplicar transfer learning:** Comenzar con un modelo preentrenado y reemplazar las capas finales.
2. **Descongelar algunas capas:** Descongelar capas intermedias del modelo (no solo las finales) para permitir que se ajusten durante el entrenamiento.
3. **Entrenar con una tasa de aprendizaje baja:** Utilizar una tasa de aprendizaje más pequeña para evitar modificar demasiado los pesos preentrenados, lo que podría dañar el conocimiento ya adquirido.

Deep neural network



Para este ejemplo se eligió el modelo RegNet



RegNet es una familia de redes neuronales convolucionales (CNN) diseñadas para tareas de visión por computadora, como clasificar imágenes. Fue creada por Facebook AI Research (FAIR) en 2020. La idea principal de RegNet es **diseñar redes de manera sistemática**, es decir, encontrar la mejor estructura para una red neuronal en lugar de probar arquitecturas al azar.

CNN desde cero vs Modelo Preentrenado

Resumen Ejecutivo

Se comparó el rendimiento de **una CNN entrenada desde cero** contra un **modelo preentrenado con fine-tuning** en un conjunto de datos específico. Los resultados muestran que:

- **La CNN desde cero logró un val_acc = 98.99%** (mejor epoch).
- **El modelo preentrenado (capas congeladas) alcanzó val_acc = 95.56%**, pero tras descongelar capas, mejoró a **val_acc = 98.33%**.

Ambos enfoques son competitivos, pero la **CNN desde cero superó ligeramente al modelo preentrenado en este caso.**

Análisis Detallado

1. Rendimiento de la CNN desde cero

- **Máximo val_acc: 98.99%** (epoch 10).
 - **train_acc \approx val_acc** (97.45% vs 98.99%), indicando **buena generalización**.
 - **Bajo overfitting:** La diferencia entre train_loss (0.079) y val_loss (0.033) es pequeña.
 - **Convergencia rápida:** En solo 10 épocas alcanzó un rendimiento excelente.
-

2. Rendimiento del Modelo Preentrenado

Fase 1: Capas Congeladas (Solo Fine-Tuning de últimas capas)

- **val_acc máximo: 95.56%** (epoch 10).
- **Rendimiento inferior a la CNN desde cero**, pero aún aceptable.
- **Posible causa:** Las características aprendidas en ImageNet no se adaptan perfectamente al dominio específico.

Fase 2: Descongelado de Capas (Fine-Tuning completo)

- **Mejor val_acc: 98.33%** (epoch 7).
- **Mayor variabilidad en val_loss** (0.052 a 0.096), sugiriendo inestabilidad al ajustar más parámetros.